

---

# Churn na comunidade

## Téo Me Why

Quem vai deixar de participar nos próximos 28 dias, e por quê?





## SUMÁRIO EXECUTIVO

# Presença nas lives e recência explicam o churn, e o top 50 do modelo acerta mais de 80%

|              |                                                                                               |                 |
|--------------|-----------------------------------------------------------------------------------------------|-----------------|
| PROBLEMA     | 48% dos ativos deixam de participar a cada 28 dias; a base caiu de ~675 para ~250 por mês.    | <b>48%</b>      |
| DADOS        | 54 features em 8 blocos (48 do sistema de pontos, 6 dos cursos), numa feature store mensal.   | <b>54</b>       |
| MODELO       | Random Forest, o melhor de 5 algoritmos. AUC num mês que o modelo nunca viu:                  | <b>0,868</b>    |
| POR QUE SAEM | Presença nas lives e recência. Churn conforme a presença nas lives aumenta:                   | <b>62% → 1%</b> |
| ENTREGA      | Lista dos 50 usuários de maior risco (jul/26). Julho já aconteceu: desses 50, saíram de fato: | <b>88%</b>      |



## — 1 · O PROBLEMA

# Quase metade dos usuários ativos sai em 28 dias

## 48%

dos ativos não voltam nos 28 dias seguintes (média de 27 meses, entre 38% e 58%)

## 675 → 250

usuários ativos por mês, de 2024 para 2026

## 352 mil

transações de pontos de 5.785 usuários analisadas

**Pergunta:** quem vai deixar de participar nos próximos 28 dias, e o que explica isso? **Churn** = 28 dias sem nenhuma transação de pontos.

**DECISÃO** Churn = 28 dias sem nenhuma transação de pontos, de qualquer valor



# 48 das 54 features vêm do sistema de pontos

## 48

do sistema de pontos (Loyalty)

## 6

da plataforma de cursos  
(Education)

Todas calculadas só com dados  
anteriores à data de referência.

A

### Perfil • 3

tempo de casa, redes  
conectadas

B

### Volume • 11

recência, dias ativos,  
frequência

C

### Tendência • 4

mês atual vs anterior,  
atraso

D

### Mix • 9

peso de cada produto

E

### Hábito • 14

horários, intervalos, streak

F

### Comunidade • 3

presença nas lives,  
lives perdidas

G

### Loja • 4

pontos gastos e saldo

H

### Educação • 6


cursos iniciados, episódios

**DECISÃO** 8 blocos MECE de hipóteses • nenhum usuário excluído, pontos como percentil • saldo atual do cadastro fora (vazamento)



### 3 · FEATURE STORE

# Quatro tabelas alimentam o treino e a predição



**Sem vazamento:** só dados anteriores à data de referência    **Incremental:** cada mês grava só a sua data    **Reuso:** treino e predição leem as mesmas features

**DECISÃO** 4 tabelas Delta, uma por bloco, gravadas mês a mês: um mês novo entra sem recalculando os anteriores.



## — 4 · ABT E VARIÁVEL-RESPOSTA

# A ABT tem 10.082 linhas de usuários ativos por mês

ANTES DA DATA DE REFERÊNCIA

**Quem entra:** 1+ transação nos 28 dias anteriores. **Features:** todo o histórico anterior.

DEPOIS DA DATA DE REFERÊNCIA

**churn = 1** se o usuário não tiver nenhuma transação nos 28 dias seguintes.

### Treino e teste

27 meses (mar/24 a mai/26)  
10.082 linhas · 3.523 usuários  
churn de 48%

### Out-of-time

jun/26, mês reservado  
que o modelo nunca vê  
churn de 44%

### Predição

jul/26: ativos em junho,  
mês fora do treino

**DECISÃO** Features de cursos só a partir de mar/25 · jun/26 inteiro reservado como out-of-time · jul/26 é a base pontuada.



# Os 5 algoritmos tiveram o mesmo preparo e critério

1

## Amostra

Um mês sorteado por usuário: ninguém aparece no treino e no teste ao mesmo tempo.  
80/20 estratificado + validação cruzada.

2

## Preparo

Nulo quase sempre é "o evento não aconteceu", não dado faltando.  
Cada nulo foi tratado pelo que significa, e o texto virou 0/1.  
Tudo ajustado só no treino, dentro do pipeline

3


## Algoritmos

Árvore, logística, Random Forest, XGBoost e LightGBM, cada um um run no MLflow.  
Escolha pela AUC da validação cruzada.

**DECISÃO** Um único pipeline para os 5 algoritmos: mesma amostra, mesmo preparo, mesmo critério de escolha.



# Sortear um mês por usuário evita vazamento, mas eleva o churn da amostra para 72%



**Por quê:** com linhas da mesma pessoa no treino e no teste, o modelo "reconhece" o usuário e a métrica sai otimista.

**Efeito colateral:** o churn da amostra sobe para 72%, porque quem fica aparece em muitos meses e quem sai, em poucos.

**Out-of-time:** jun/26 fica de fora, com todos os ativos do mês, para a validação final.

**DECISÃO** Um mês sorteado por usuário (como na aula 3) · 80/20 estratificado · validação cruzada em 3 partes.



# A maioria dos nulos significa que nada aconteceu

| Tipo de dado                | Colunas                                                            | O nulo significa                    | Tratamento                |
|-----------------------------|--------------------------------------------------------------------|-------------------------------------|---------------------------|
| Dias desde o último evento  | diasUltimoStreak, diasDesdeUltimoEp                                | nunca fez                           | máximo da base            |
| Intervalo entre dias ativos | avgIntervalo, maxIntervalo, razaoAtraso, stdIntervalo, cvIntervalo | poucos dias ativos para medir       | máximo da base            |
| Plataforma de cursos        | qtdCursosIniciados, qtdEpsD28, flFezCurso...                       | mês antes de mar/25, sem plataforma | 0 + indicador de ausência |
| Cadastro                    | qtdRedes                                                           | usuário fora do cadastro            | 0                         |

Tudo dentro do pipeline (feature\_engine), ajustado **só no treino**: o teste, o out-of-time e a predição recebem o mesmo tratamento, sem vazamento.

**DECISÃO** Imputar pelo significado do nulo, não pela média · tudo ajustado só no treino, dentro do pipeline.




# Só a regressão logística precisou de escala

## Texto → 0/1

OneHotEncoder em tendência, período e produto dominante, streak e uso da loja.

Colunas com 2 opções viram uma só; categoria nova no teste fica 0 em todas.

ORDEM NO PIPELINE



## Escala

**StandardScaler só na logística:** ela soma as features com pesos, então a unidade importa.

**Árvores não precisam:** cortam por limiares, e a ordem dos valores não muda com a escala. Min-Max não foi usado.

**DECISÃO** StandardScaler só na logística · sem Min-Max · colunas de 2 opções viram uma só coluna 0/1.



## O boosting decorou o treino: LightGBM teve AUC 0,98

| Algoritmo           | Como funciona                                             | Configuração                         | Força · cuidado                                      |
|---------------------|-----------------------------------------------------------|--------------------------------------|------------------------------------------------------|
| Árvore de decisão   | Uma sequência de regras "se... então"                     | min_samples_leaf = 50                | fácil de explicar · instável                         |
| Regressão logística | Soma ponderada das features, passada por uma sigmoide     | StandardScaler, max_iter = 2000      | pesos interpretáveis · só relações lineares          |
| Random Forest       | 500 árvores em amostras diferentes; a previsão é a média  | min_samples_leaf = 12                | robusto a ruído · probabilidades puxadas para o meio |
| XGBoost             | Árvores em sequência, cada uma corrige o erro da anterior | 300 árvores, lr 0,05, profundidade 4 | muito preciso · mais parâmetros para ajustar         |
| LightGBM            | Boosting que cresce a árvore pela folha de maior ganho    | 300 árvores, lr 0,05, 15 folhas      | rápido · overfitting em base pequena                 |

Mesmo preparo e um run no MLflow para cada. A escolha usa a **AUC da validação cruzada**, não a de treino.

**DECISÃO** Hiperparâmetros conservadores (folhas mínimas, árvores rasas) para conter o overfitting numa base de ~2.800 linhas.



## Random Forest: 0,819 na validação, 0,780 no teste

| MODELO                    | AUC TREINO | AUC VALIDAÇÃO<br>CRUZADA | AUC TESTE | AUC OUT-OF-TIME |
|---------------------------|------------|--------------------------|-----------|-----------------|
| Random Forest (escolhido) | 0,912      | 0,819                    | 0,780     | 0,868           |
| Regressão logística       | 0,827      | 0,805                    | 0,784     | 0,816           |
| XGBoost                   | 0,935      | 0,802                    | 0,769     | 0,825           |
| LightGBM                  | 0,978      | 0,792                    | 0,772     | 0,828           |
| Árvore de decisão         | 0,862      | 0,773                    | 0,760     | 0,842           |
| Referência: só a recência | —          | —                        | 0,712     | —               |

**Treino:** AUC nos mesmos 80% usados no ajuste (otimista por definição). **Validação cruzada:** média da AUC em 3 dobras desses 80%, cada uma avaliada pelo modelo ajustado nas outras duas; é ela que escolhe o modelo. **Teste:** 20% separados antes de tudo (estratificado), avaliados uma vez. **Out-of-time:** jun/26.




# Cada AUC responde a uma pergunta diferente

| dobra 1                                                                                                                                 | dobra 2                                                                                                                                                     | dobra 3                                                                                                                         | teste                                                                                                                              | jun/26      |
|-----------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------|-------------|
| Treino · 80% das safras até mai/26 (uma por usuário)                                                                                    |                                                                                                                                                             |                                                                                                                                 | Teste · 20%                                                                                                                        | Out-of-time |
| <b>Treino</b><br><br><b>0,912</b><br><br>Nos mesmos 80% usados no ajuste: mostra quanto o modelo decora.<br><br><b>Uso: diagnóstico</b> | <b>Validação cruzada</b><br><br><b>0,819</b><br><br>Ajusta em 2 dobras e mede na 3ª, que não viu; média das 3 rodadas.<br><br><b>Uso: escolher o modelo</b> | <b>Teste</b><br><br><b>0,780</b><br><br>20% separados no início e avaliados uma única vez.<br><br><b>Uso: medir o escolhido</b> | <b>Out-of-time</b><br><br><b>0,868</b><br><br>Mês depois de todo o treino, como em produção.<br><br><b>Uso: confirmar no tempo</b> |             |

**DECISÃO** Com 5 modelos, a escolha usa a validação cruzada; teste e out-of-time ficam isentos para medir. Valores do Random Forest.



## Em junho, 80% do top 50 saiu: 1,8× a média



0,868

AUC no out-of-time (jun/26), acima do teste (0,780)

80%

do top 50 saiu de fato, contra 44% da média: 1,8× mais acerto

As probabilidades saem altas (55% previsto contra 44% real), mas a ordem está certa. A recalibração fica para a v1.


**DECISÃO** O out-of-time só confirma a escolha feita pela validação cruzada, cuja curva fica colada na do teste. Expectativa realista em produção: AUC entre 0,78 e 0,82.



## 6 · IMPORTÂNCIA DAS VARIÁVEIS

# Afastamento recente e lives explicam o churn

### IMPORTÂNCIA POR BLOCO



### TOP 5 FEATURES · MÉDIA

| Feature                              | Fica | Sai |
|--------------------------------------|------|-----|
| % das lives com presença             | 26%  | 10% |
| Lives perdidas desde a última visita | 3,8  | 8,6 |
| Recência (dias)                      | 7    | 14  |
| Dias ativos, últimos 7 dias          | 1,7  | 0,5 |
| Dias ativos, últimos 14 dias         | 2,8  | 0,8 |


Educação quase não separa quem sai de quem fica.

**DECISÃO** Ler a importância por tema: recência e lives perdidas têm correlação de 0,96 e dividem o crédito entre si.



## 6 · IMPORTÂNCIA · LIVES

# Com mais lives, o churn cai de 62% para 1%



Taxa de churn por % **das lives com presença** nos últimos 28 dias.  
Média da base: 48%.



## 7 · LISTA DE CLIENTES

# Em julho, 88% do top 50 saiu: 2× a média

| #   | Usuário     | Prob. churn |
|-----|-------------|-------------|
| 1   | 2558d88c... | 94,8%       |
| 2   | 1dc954ac... | 94,8%       |
| 3   | bd91649f... | 93,6%       |
| 4   | 8e344345... | 92,9%       |
| 5   | c88b213c... | 92,8%       |
| 6   | a61f1c0f... | 92,5%       |
| 7   | 71bdfe19... | 92,1%       |
| 8   | 868d1d71... | 92,1%       |
| ... | ...         | ...         |
| 50  | 809ed01f... | 82,6%       |

Lista completa: output/tables/top50\_churn\_2026-07-01.csv

### Base

Usuários ativos em junho, pontuados pelo modelo registrado no MLflow.

### Resultado em julho

88% desses 50 saíram de fato, contra 45% da média do mês: 2,0× mais acerto.

### Leitura

Vale como ranking: as probabilidades ainda estão acima do real.

**DECISÃO** Predição sem retreinar: carrega o modelo champion do MLflow e pontua jul/26, o mesmo corte da aula.



# A v1 deve recalibrar e reduzir o overfitting

[github.com/by-anasantos/ds-churn-teo-me-why](https://github.com/by-anasantos/ds-churn-teo-me-why)

README com o papel de cada notebook, as decisões técnicas, os nulos e a análise exploratória.

## PRÓXIMOS PASSOS · V1

### Recalibrar

probabilidades altas: previsto 55%, real 44%

### Validação temporal

treinar até um mês e validar no seguinte para escolher o modelo

### Testar a logística

empata na ordenação e decora menos o treino (4 contra 13 pontos)

### Redundância

features correlacionadas, importância por permutação

### Monitorar

desempenho a cada novo mês

### Cursos

tempo entre o início e o fim de cada curso